

# IA “bebe” água?

Energia, refrigeração e a pegada hídrica dos modelos de linguagem

Enzo Cezaretti Pezzotti

2026

## Resumo

A popularização de grandes modelos de linguagem trouxe também afirmações simplificadas sobre seu impacto ambiental, entre elas a ideia de que uma pergunta feita a uma inteligência artificial “consome” determinada quantidade fixa de água. Este artigo apresenta os conceitos físicos e computacionais necessários para interpretar corretamente essa discussão.

A partir de trabalhos sobre eficiência hídrica de data centers e dos estudos de Li et al. (2025) e Elsworth et al. (2025), discute-se como a inferência de modelos de linguagem demanda energia elétrica, produz calor e depende de uma infraestrutura de refrigeração cuja operação pode possuir pegada hídrica direta e indireta.

O objetivo não é negar o impacto ambiental da inteligência artificial, mas mostrar por que valores de energia ou água por prompt dependem do modelo, do hardware, da infraestrutura, da localização e da metodologia de medição.

**Palavras-chave:** inteligência artificial; LLM; data center; energia; refrigeração; consumo de água; sustentabilidade.

## 1 Introdução

Nos últimos anos tornou-se comum afirmar que sistemas de inteligência artificial “bebem água”. A expressão chama atenção para um impacto ambiental real, mas pode sugerir uma interpretação fisicamente imprecisa: um modelo de linguagem não utiliza água como insumo direto para calcular uma resposta.

A cadeia física é mais longa. Uma inferência exige processamento em servidores e aceleradores computacionais; esses equipamentos demandam energia elétrica e dissipam calor; o calor precisa ser removido; e determinados sistemas de refrigeração utilizam água para rejeitá-lo ao ambiente.

Além disso, a própria geração da eletricidade consumida pelo data center pode possuir uma pegada hídrica.

De forma simplificada,

LLM  $\rightarrow$  computação  $\rightarrow$  energia elétrica  $\rightarrow$  calor  $\rightarrow$  refrigeração  $\rightarrow$  possível consumo de água. (1)

O objetivo deste artigo é reconstruir essa cadeia, apresentar como a discussão sobre água em data centers antecede os LLMs e comparar duas etapas importantes da literatura recente: a estimativa da pegada hídrica da IA apresentada por Li et al. (2025) e a medição de inferência em infraestrutura real de produção apresentada por Elsworth et al. (2025).

## 2 Da inferência ao calor

Durante a inferência, um modelo de linguagem executa operações matemáticas em aceleradores como GPUs ou TPUs, além de utilizar memória, processadores, interconexões e outros componentes do servidor.

Esses equipamentos consomem potência elétrica durante o processamento.

A relação elementar entre energia, potência e tempo é

$$E = P t, \quad (2)$$

em que  $E$  representa a energia consumida,  $P$  a potência média e  $t$  o tempo de operação.

Do ponto de vista térmico, praticamente toda a energia elétrica entregue aos equipamentos de computação termina convertida em calor no ambiente do data center.

Assim, além da energia utilizada diretamente pelo hardware de TI, existe energia associada a sistemas auxiliares, principalmente refrigeração, conversão elétrica, bombeamento e ventilação.

Uma métrica frequentemente utilizada para representar essa relação é o *Power Usage Effectiveness* (PUE):

$$PUE = \frac{\text{energia total do data center}}{\text{energia dos equipamentos de TI}}. \quad (3)$$

Um PUE igual a 1 representaria, idealmente, toda a energia sendo utilizada pelos equipamentos de TI.

Na prática, o valor é superior a 1 devido ao consumo da infraestrutura auxiliar.

O estudo de Elsworth et al. (2025) é particularmente relevante porque inclui, em sua fronteira de medição, não apenas os aceleradores ativos, mas também sistemas host, capacidade ociosa e o *overhead* energético do data center.

### 3 Onde entra a água?

A expressão “consumo de água da IA” agrega mecanismos fisicamente distintos.

Uma separação útil é considerar pelo menos três níveis: água utilizada diretamente no data center, água associada à geração da eletricidade e água incorporada à fabricação da infraestrutura computacional.

#### 3.1 Água direta no data center

Sistemas de refrigeração evaporativa podem utilizar água para rejeitar ao ambiente o calor produzido pelos equipamentos.

Nesses casos, parte da água evapora durante o processo e constitui consumo hídrico direto associado à operação do data center.

A água, portanto, não é consumida pelo algoritmo ou pelo modelo de linguagem em si, mas por uma infraestrutura física responsável por manter as condições térmicas necessárias ao funcionamento dos equipamentos.

#### 3.2 Água associada à eletricidade

Mesmo um data center que não utilize água diretamente para refrigeração continua dependendo de eletricidade.

Dependendo da tecnologia e da região, a geração dessa eletricidade pode envolver retirada e consumo de água.

Li et al. (2025) destacam que a pegada hídrica da inteligência artificial deve considerar também esse componente indireto.

Dessa forma, mesmo quando não existe consumo hídrico significativo dentro do próprio data center, parte da pegada pode estar localizada fora dele, na cadeia de produção da energia elétrica.

### 3.3 Água incorporada ao hardware

Existe ainda água utilizada na cadeia de fabricação dos equipamentos, incluindo processos industriais relacionados à produção de semicondutores.

A fabricação de circuitos integrados exige processos de elevada pureza e pode envolver grandes quantidades de água ultrapura.

Esse componente pertence a uma análise de ciclo de vida mais ampla e não será quantificado neste artigo, mas deve ser reconhecido para evitar que “água por prompt” seja interpretada como uma medida completa de todo o impacto material de um sistema de inteligência artificial.

## 4 Retirada de água não é consumo de água

Um ponto conceitual importante é distinguir *water withdrawal* de *water consumption*.

- **Retirada de água (*withdrawal*):** volume removido de uma fonte para uso em determinado processo.
- **Consumo de água (*consumption*):** parcela que deixa de retornar imediatamente ao mesmo sistema hídrico, por exemplo por evaporação.

Essa diferença é central no trabalho de Li et al. (2025).

Uma instalação pode retirar grande quantidade de água, utilizar parte em um processo e devolver outra parcela ao ambiente. Em outro sistema, uma retirada menor pode resultar em proporção maior de água efetivamente consumida.

Dois estudos podem, portanto, apresentar números diferentes simplesmente porque utilizam fronteiras, locais e definições distintas.

Consequentemente, uma afirmação como “uma IA utiliza X litros de água” é incompleta se não informa qual métrica está sendo considerada.

## 5 Antes dos LLMs: data centers já eram “sedentos”

A preocupação com o consumo hídrico da infraestrutura computacional antecede a popularização da inteligência artificial generativa.

Em 2014, Islam et al. (2014) apresentaram um trabalho voltado especificamente ao uso de água em data centers.

Os autores trataram o data center como um sistema ciberfísico: de um lado, servidores e cargas computacionais; de outro, refrigeração e demais ativos físicos.

O estudo explorou a variação temporal da eficiência hídrica e propôs o algoritmo WACE (*minimization of WAter, Carbon and Electricity cost*), que deslocava cargas tolerantes a atraso para períodos mais favoráveis.

Nas simulações apresentadas pelos autores, a estratégia reduziu em mais de 27% o consumo de água em comparação com as referências avaliadas (Islam et al., 2014).

Esse trabalho é importante historicamente porque demonstra que o problema não surgiu com o ChatGPT ou com os LLMs.

A inteligência artificial generativa passou a representar uma nova classe de carga computacional dentro de uma discussão anterior sobre energia, refrigeração, carbono e água em data centers.

## 6 Li et al.: tornando visível a pegada hídrica da IA

A primeira versão de *Making AI Less “Thirsty”* foi disponibilizada em 2023 e o trabalho foi posteriormente publicado, em 2025, na *Communications of the ACM* (Li et al., 2025).

Pengfei Li, Jianyi Yang, Mohammad A. Islam e Shaolei Ren buscaram construir uma metodologia para estimar a pegada hídrica de modelos de inteligência artificial e discutir sua variação espacial e temporal.

O trabalho ganhou destaque por trazer para a discussão de inteligência artificial um recurso que recebia menos atenção pública do que energia e emissões de carbono.

Uma das principais contribuições conceituais do estudo é mostrar que a pegada hídrica não deve ser tratada como uma constante do modelo.

Ela depende de fatores como:

- eficiência do data center;
- tecnologia de refrigeração;
- localização geográfica;
- condições climáticas;
- horário de execução;
- matriz de geração elétrica;
- quantidade e tipo de computação executada.

O trabalho também originou estimativas que foram amplamente reproduzidas em discussões públicas sobre “garrafas de água” associadas a respostas de IA.

Entretanto, essas estimativas correspondem a cenários e hipóteses específicos, e não a uma constante física universal de consumo por pergunta (Li et al., 2025).

Esse cuidado é essencial: transformar uma estimativa associada a determinado modelo, infraestrutura e localização em uma regra geral para toda inteligência artificial elimina justamente as variáveis que o próprio estudo procura evidenciar.

## 7 Elsworth et al.: da estimativa à telemetria de produção

Em 2025, Elsworth et al. (2025) abordaram o problema por outra perspectiva.

Em vez de estimar o impacto de uma inferência apenas a partir de especificações de hardware, os autores propuseram uma metodologia de medição para uma infraestrutura real e de grande escala utilizada para servir o Gemini.

A fronteira de medição inclui aceleradores ativos, energia dos sistemas host, capacidade ociosa das máquinas e *overhead* do data center.

Para o prompt textual mediano do Gemini Apps analisado no estudo, os autores reportaram

$$E_{\text{prompt}} \approx 0,24 \text{ Wh} \quad (4)$$

e consumo hídrico de aproximadamente

$$W_{\text{prompt}} \approx 0,26 \text{ mL}. \quad (5)$$

Esses valores não devem ser convertidos em uma regra para “qualquer pergunta a qualquer IA”.

Eles representam uma carga, um sistema e uma metodologia específicos.

A principal contribuição do estudo é metodológica: comparações ambientais entre sistemas de inteligência artificial exigem fronteiras de medição explícitas e consistentes (Elsworth et al., 2025).

Isso também ajuda a explicar por que estimativas publicadas em diferentes momentos podem divergir significativamente sem que uma delas seja necessariamente inválida.

Se modelo, hardware, software, utilização, refrigeração e localização mudam, o resultado energético e hídrico também pode mudar.

## 8 Por que os números por prompt mudam tanto?

Não existe uma constante universal de energia por resposta.

Uma representação conceitual é

$$E_{\text{prompt}} = f(M, H, N_{\text{in}}, N_{\text{out}}, B, U, D), \quad (6)$$

em que:

- $M$  representa o modelo;
- $H$  representa o hardware;
- $N_{\text{in}}$  representa a quantidade de tokens de entrada;
- $N_{\text{out}}$  representa a quantidade de tokens gerados;
- $B$  representa estratégias como *batching*;
- $U$  representa a utilização efetiva do hardware;
- $D$  representa características da infraestrutura do data center.

De maneira semelhante, a água associada a uma inferência pode ser entendida como dependente da energia consumida, da eficiência hídrica do data center, da refrigeração, da localização, do clima e da matriz elétrica:

$$W_{\text{prompt}} = f(E, WUE, \text{clima}, \text{localização}, \text{matriz elétrica}, \text{refrigeração}). \quad (7)$$

Nessa expressão, WUE corresponde ao *Water Usage Effectiveness*, uma métrica utilizada para relacionar o uso de água da infraestrutura à energia associada aos equipamentos de TI.

As duas expressões apresentadas não pretendem formar um modelo quantitativo completo.

Seu objetivo é evidenciar que energia e água por prompt são resultados de um sistema e não propriedades fixas de um LLM.

## 9 Água versus energia: um problema de otimização

A relação entre energia e água não é necessariamente monotônica.

Sistemas que utilizam evaporação podem, em determinadas condições, rejeitar calor com menor demanda elétrica do que alternativas de refrigeração seca.

Assim, reduzir o uso direto de água pode exigir mais energia, enquanto reduzir energia nem sempre reduz a pegada hídrica indireta.

Por isso,

$$\text{menor uso de água} \not\Rightarrow \text{menor consumo de energia}, \quad (8)$$

e a análise ambiental precisa considerar simultaneamente diferentes objetivos:

$$\boxed{\text{Energia} + \text{Água} + \text{Carbono}}. \quad (9)$$

A localização também importa.

O impacto de consumir determinada quantidade de água em uma região com alta disponibilidade hídrica não é necessariamente o mesmo de consumi-la em uma região submetida a escassez hídrica.

Portanto, avaliar apenas o volume absoluto utilizado também pode ser insuficiente para representar o impacto ambiental local.

## 10 Propostas derivadas dessa linha de pesquisa

Os trabalhos analisados apontam para duas famílias complementares de estratégias.

### 10.1 Gerenciamento consciente de água e carbono

A linha de Islam et al. (2014) e Li et al. (2025) sugere explorar a flexibilidade espacial e temporal das cargas computacionais.

Exemplos incluem agendar cargas para períodos de maior eficiência hídrica, selecionar regiões mais favoráveis e avaliar água e carbono de maneira conjunta.

Em princípio, uma tarefa computacional que não precisa ser executada imediatamente pode ser deslocada para um horário ou local em que seu impacto associado seja menor.

Essa lógica transforma a sustentabilidade em um problema de gerenciamento de recursos computacionais.

### 10.2 Medição e eficiência do sistema completo

O estudo de Elsworth et al. (2025) destaca que reduzir o impacto por inferência exige medir e otimizar todo o sistema de *serving*, e não apenas a potência nominal de uma GPU.

Melhorias podem surgir de:

- hardware mais eficiente;
- maior utilização dos aceleradores;
- otimizações de software;
- *batching*;
- técnicas de *serving*;
- redução de capacidade ociosa;
- otimização conjunta entre hardware e software;
- melhorias na própria infraestrutura do data center.

Assim, reduzir o impacto ambiental de uma inferência não significa apenas utilizar um acelerador que consuma menos potência.

O desempenho energético depende da eficiência do sistema completo.

## 11 O problema da escala

O impacto de uma única inferência pode ser pequeno e, simultaneamente, o impacto agregado de uma infraestrutura global pode ser relevante.

De forma elementar,

$$E_{\text{total}} = E_{\text{inferência}} \times N_{\text{inferências}}. \quad (10)$$

Portanto, duas afirmações podem ser verdadeiras ao mesmo tempo:

uma pergunta individual pode consumir uma pequena quantidade de energia e água;

e

bilhões de inferências, treinamento de modelos e expansão de data centers podem produzir uma demanda material de eletricidade e recursos hídricos.

Essa distinção evita tanto a banalização do impacto quanto a transformação de estimativas específicas em slogans universais.

A escala, portanto, é parte essencial da discussão.

Uma quantidade aparentemente pequena associada a uma única interação pode se tornar relevante quando multiplicada por milhões ou bilhões de operações.

## 12 Limitações e cuidados de interpretação

Este artigo apresenta conceitos e resultados publicados, mas não realiza uma medição independente de consumo elétrico ou hídrico.

As estimativas de Li et al. (2025) e as medições de Elsworth et al. (2025) não devem ser comparadas como se fossem experimentos idênticos.

Os trabalhos utilizam modelos, períodos, infraestruturas, fronteiras de medição e metodologias diferentes.

Também é importante separar:

- impacto associado à inferência;
- impacto associado ao treinamento;
- impacto operacional do data center;
- impacto da geração de eletricidade;
- impacto de ciclo de vida do hardware.

Uma única métrica expressa em mL por prompt não resume todos esses componentes.

Da mesma forma, uma estimativa de energia por resposta não pode ser utilizada como característica universal de todos os modelos de linguagem.

## 13 Considerações finais

A afirmação de que a inteligência artificial “bebe água” parte de um fenômeno real, mas comprime uma cadeia técnica complexa em uma metáfora.

Modelos de linguagem demandam computação; a computação demanda eletricidade e produz calor; o calor precisa ser removido; e a infraestrutura utilizada para isso pode consumir água direta ou indiretamente.

Trabalhos anteriores à popularização dos LLMs já discutiam como reduzir a pegada hídrica de data centers.

Li et al. (2025) levaram essa discussão para a escala dos modelos de inteligência artificial e evidenciaram a importância de medir água junto com energia e carbono.

Elsworth et al. (2025), por sua vez, demonstraram a importância de medir o sistema completo de inferência em produção e de definir claramente quais componentes estão incluídos em uma estimativa ambiental.

Assim, a interpretação mais adequada não é que uma IA consuma uma quantidade fixa de água por pergunta.

A conclusão tecnicamente mais consistente é:

**a IA não “bebe” uma quantidade fixa de água,  
mas a infraestrutura que permite seu funcionamento  
possui uma pegada hídrica real, variável e mensurável.**

A discussão, portanto, não deve ser reduzida à pergunta “quantos mililitros uma resposta consome?”.

Uma análise tecnicamente adequada exige perguntar:

*qual modelo foi utilizado, em qual hardware, em qual infraestrutura, com qual sistema de refrigeração, em qual local e segundo qual metodologia de medição?*

É a resposta a esse conjunto de perguntas que permite interpretar corretamente o impacto energético e hídrico associado aos modelos de linguagem.

## Referências

ISLAM, M. A.; AHMED, K.; REN, S.; QUAN, G.

*Exploiting Temporal Diversity of Water Efficiency to Make Data Center Less “Thirsty”.*

In: 11th International Conference on Autonomic Computing (ICAC 14). Philadelphia, PA: USENIX Association, 2014. p. 145–152.

Disponível em:

<https://www.usenix.org/conference/icac14/technical-sessions/presentation/islam>.

LI, P.; YANG, J.; ISLAM, M. A.; REN, S.

*Making AI Less “Thirsty”: Uncovering and Addressing the Secret Water Footprint of AI Models.*

Communications of the ACM, v. 68, n. 7, p. 54–61, 2025.

DOI:

<https://doi.org/10.1145/3724499>.

Versão inicial disponibilizada no arXiv em 2023:

<https://arxiv.org/abs/2304.03271>.

ELSWORTH, C.; HUANG, K.; PATTERSON, D.; SCHNEIDER, I.; SEDIVY, R.; GOODMAN, S.; TOWNSEND, B.; RANGANATHAN, P.; DEAN, J.; VAHDAT, A.; GOMES, B.; MANYIKA, J.

*Measuring the Environmental Impact of Delivering AI at Google Scale.*

arXiv preprint arXiv:2508.15734, 2025.

Disponível em:

<https://arxiv.org/abs/2508.15734>.