

Janela de Contexto em Modelos de Linguagem

Quando mais contexto não significa melhor uso da informação

Enzo Cezaretti Pezzotti

2026

Resumo

Este artigo apresenta, de forma introdutória, o conceito de contexto em grandes modelos de linguagem (*Large Language Models* – LLMs) e discute uma limitação observada no uso de contextos extensos.

A análise toma como referência principal o trabalho *Lost in the Middle: How Language Models Use Long Contexts*, de Liu et al. (2024). O objetivo é distinguir a capacidade nominal de uma janela de contexto da capacidade efetiva de um modelo utilizar, de maneira uniforme, as informações contidas nela.

Trabalhos posteriores são considerados para mostrar como a discussão evoluiu da posição de uma única informação relevante para problemas relacionados à recuperação, integração e raciocínio sobre múltiplas informações distribuídas em contextos longos.

Palavras-chave: modelos de linguagem; LLM; janela de contexto; contexto longo; inteligência artificial.

1 Introdução

Modelos de linguagem modernos podem receber grandes quantidades de texto durante uma única interação. Essa capacidade permite aplicações envolvendo documentos extensos, múltiplas fontes e históricos longos de conversação.

Entretanto, a capacidade de *receber* informação não implica necessariamente a capacidade de *utilizá-la* de forma uniforme.

O trabalho de Liu et al. (2024) investiga justamente essa diferença ao avaliar como a posição de uma informação relevante dentro de um contexto longo afeta o desempenho de diferentes modelos.

Essa discussão leva a uma pergunta fundamental:

Se determinada informação cabe dentro da janela de contexto, o modelo consegue utilizá-la com a mesma eficiência independentemente de sua posição e da quantidade de informação ao redor?

2 O que é contexto em uma LLM?

Em um modelo de linguagem, o termo *contexto* não deve ser entendido como memória no sentido humano, nem como sinônimo de todo o conhecimento acumulado pelo modelo.

Durante a inferência, o modelo recebe uma sequência ordenada de unidades discretas de texto, denominadas *tokens*, e utiliza essa sequência como condição para calcular a distribuição de probabilidade do próximo token.

Em um modelo autorregressivo, essa ideia pode ser representada por:

$$P(x_t \mid x_1, x_2, \dots, x_{t-1}), \quad (1)$$

em que x_t representa o próximo token a ser produzido e $x_1, \dots, x_{t-1}$ representam os tokens disponíveis ao modelo naquele instante.

A arquitetura Transformer introduziu o mecanismo de atenção como elemento central para estabelecer relações entre diferentes posições de uma sequência (Vaswani et al., 2017). Dessa forma, o processamento do próximo token pode considerar relações entre diferentes elementos presentes no contexto.

Um marco histórico importante para a utilização do contexto em modelos de grande escala foi o GPT-3. Brown et al. (2020) demonstraram que instruções e exemplos apresentados diretamente na entrada podiam orientar a realização de diferentes tarefas sem uma nova etapa de atualização dos parâmetros do modelo.

O GPT-3 é citado aqui como referência histórica para o desenvolvimento do *in-context learning*, e não como representante do estado atual dos grandes modelos de linguagem.

Assim, neste artigo, **contexto** é definido como a sequência de informação tokenizada disponibilizada ao modelo durante uma inferência e utilizada para condicionar sua geração subsequente.

Em aplicações práticas, essa sequência pode ser composta por:

- instruções;
- perguntas do usuário;
- exemplos;
- histórico textual;
- trechos de documentos;
- informações recuperadas de fontes externas;
- tokens já produzidos durante a própria geração.

Sistemas de geração aumentada por recuperação (*Retrieval-Augmented Generation* – RAG), por exemplo, recuperam passagens de uma fonte externa e as utilizam para condicionar a geração, mantendo uma distinção entre o conhecimento paramétrico do modelo e uma memória externa não paramétrica (Lewis et al., 2020).

2.1 Contexto não é o mesmo que conhecimento do modelo

É útil distinguir pelo menos três formas de informação envolvidas no funcionamento de um sistema baseado em LLM.

A primeira é o **conhecimento paramétrico**, incorporado aos parâmetros do modelo durante o treinamento.

A segunda é a **informação em contexto**, fornecida durante a própria inferência e utilizada sem que seja necessário alterar os parâmetros do modelo.

A terceira, quando presente, é uma **fonte externa de informação**, como uma base documental consultada por um mecanismo de recuperação antes da geração (Brown et al., 2020; Lewis et al., 2020).

De maneira simplificada:

1. **Conhecimento paramétrico:** informação incorporada aos parâmetros durante o treinamento;

2. **Contexto:** informação disponibilizada diretamente ao modelo durante a inferência;
3. **Informação externa:** conteúdo armazenado fora do modelo, que pode ser recuperado e introduzido no contexto quando necessário.

Essa distinção explica por que um modelo pode responder sobre um documento que não estava presente em seu treinamento: o documento não precisa se transformar em novo conhecimento paramétrico para influenciar a resposta; basta que seu conteúdo relevante seja introduzido no contexto da inferência.

2.2 Janela de contexto

A *janela de contexto* corresponde ao limite da sequência que o modelo consegue processar como contexto em uma determinada configuração.

A existência de um comprimento limitado é uma característica historicamente importante dos Transformers aplicados à modelagem de linguagem. Trabalhos como o Transformer-XL foram motivados justamente pela dificuldade de capturar dependências além de um contexto de comprimento fixo (Dai et al., 2019).

Entretanto, o tamanho nominal da janela e a utilização efetiva das informações nela contidas são propriedades diferentes.

Um modelo pode aceitar uma sequência longa sem necessariamente utilizar todas as posições dessa sequência com a mesma robustez.

Essa diferença é central para o trabalho *Lost in the Middle*, que mostra variações de desempenho conforme a posição da informação relevante no contexto (Liu et al., 2024).

**A janela de contexto determina quanto o modelo pode receber;
não necessariamente quanto ele consegue utilizar com a mesma eficiência.**

3 O problema dos contextos longos

Considere um sistema que recebe dezenas de documentos e precisa responder a uma pergunta cuja evidência está presente em apenas um deles.

Idealmente, se todos os documentos estão dentro da janela de contexto, a posição do documento relevante não deveria modificar significativamente a capacidade do modelo de encontrar e utilizar a informação correta.

Essa hipótese é colocada à prova em *Lost in the Middle*.

4 O experimento *Lost in the Middle*

4.1 Pergunta de pesquisa

A pergunta central do trabalho pode ser expressa de maneira simples:

A posição da informação relevante dentro de um contexto longo influencia o desempenho do modelo?

4.2 Tarefas avaliadas

O estudo avalia modelos em duas tarefas principais: resposta a perguntas com múltiplos documentos (*multi-document question answering*) e recuperação sintética de pares chave–valor (*key-value retrieval*) (Liu et al., 2024).

Na primeira tarefa, diversos documentos são fornecidos ao modelo, mas somente um contém a evidência necessária para responder à pergunta. A posição desse documento é modificada dentro do conjunto.

Na segunda, os pesquisadores utilizam uma tarefa controlada de recuperação de pares chave–valor, permitindo determinar precisamente onde a informação relevante se encontra.

4.3 Resultado central

Os resultados apresentados por Liu et al. (2024) mostram que a posição da informação relevante dentro do contexto pode influenciar de maneira significativa a capacidade do modelo de utilizá-la.

Em diversas configurações avaliadas, o desempenho foi maior quando o documento contendo a informação necessária estava localizado próximo ao início ou ao final da sequência, enquanto posições intermediárias apresentaram redução de acurácia.

Esse comportamento produz, em vários dos experimentos, uma tendência semelhante a uma curva em “U”: maior desempenho nas extremidades e menor desempenho na região central do contexto. Os autores denominaram esse fenômeno *Lost in the Middle* (Liu et al., 2024).

A Figura 1 sintetiza os principais cenários avaliados no trabalho. Os gráficos consideram diferentes quantidades de documentos recuperados e, conseqüentemente, diferentes extensões aproximadas de contexto. O eixo horizontal representa a posição do documento que contém a informação necessária para responder à pergunta, enquanto o eixo vertical representa a acurácia obtida pelos modelos.

No primeiro conjunto de experimentos, com aproximadamente 10 documentos recuperados, observa-se que diversos modelos apresentam maior acurácia quando o documento relevante ocupa a primeira posição.

À medida que essa informação é deslocada para posições intermediárias, o desempenho diminui, com recuperação parcial quando o documento é colocado próximo ao final do contexto.

Esse comportamento torna-se ainda mais evidente nos experimentos com 20 e 30 documentos. Com o aumento da quantidade de informação fornecida ao modelo, a posição da evidência necessária passa a produzir diferenças mais pronunciadas em algumas configurações.

Em particular, determinados modelos apresentam uma queda acentuada de desempenho quando a informação relevante deixa a primeira posição e passa a ocupar regiões intermediárias da sequência.

Os autores também avaliaram modificações na forma como a pergunta é apresentada ao modelo. No cenário denominado *query-aware contextualization*, a consulta é utilizada explicitamente durante a organização do contexto.

Embora essa estratégia modifique o desempenho absoluto dos modelos, a influência da posição da informação continua presente, mostrando que a simples reformulação do contexto não elimina necessariamente o problema.

Outro resultado relevante aparece na comparação entre versões do MPT-30B. Quando modelos ajustados para seguir instruções são comparados às respectivas versões básicas, observa-se uma melhora importante na capacidade de utilizar informações distribuídas ao longo do contexto.

Entretanto, mesmo nesses casos, o desempenho ainda não é perfeitamente uniforme entre todas as posições.




Figura 1: Representação dos resultados associados ao fenômeno *Lost in the Middle* em diferentes configurações experimentais. O eixo horizontal indica a posição do documento que contém a informação necessária para responder à pergunta, enquanto o eixo vertical representa a acurácia obtida. Os diferentes gráficos apresentam cenários com 10, 20 e 30 documentos recuperados, além de variações na forma de contextualização e em modelos ajustados especificamente para seguir instruções. Adaptado de Liu et al. (2024).

A Figura 1 também evidencia que o fenômeno não deve ser interpretado como uma curva idêntica para todos os modelos.

A magnitude da queda, a posição de menor desempenho e a recuperação observada no final da sequência variam de acordo com o modelo e com a configuração experimental.

O resultado relevante é, portanto, a existência de uma **dependência sistemática entre a posição da informação e a capacidade de utilizá-la**, e não a existência de uma curva universal.

Essa observação é particularmente importante porque todos os documentos utilizados nos experimentos permaneciam formalmente dentro da janela de contexto dos modelos.

A limitação observada, portanto, não estava relacionada à impossibilidade de receber a informação, mas à capacidade de utilizá-la de maneira igualmente robusta dependendo de sua posição.

Em outras palavras:

Uma informação estar presente dentro da janela de contexto não garante que sua contribuição para a resposta será equivalente em qualquer posição dessa janela.

Essa diferença entre *informação disponível* e *informação efetivamente utilizada* constitui o principal resultado do trabalho e fornece a base para discussões posteriores sobre a diferença entre janela nominal e contexto efetivamente utilizável.

5 Do *Lost in the Middle* ao contexto efetivo

Desde a publicação de *Lost in the Middle*, os modelos de linguagem evoluíram significativamente em sua capacidade nominal de processar sequências extensas.

Entretanto, estudos posteriores indicam que o aumento da janela de contexto não eliminou as dificuldades relacionadas à utilização efetiva dessas informações.

5.1 RULER: a janela nominal não é necessariamente a janela efetiva

O benchmark RULER mostrou que um modelo pode apresentar desempenho praticamente perfeito em tarefas simples de recuperação, como *needle-in-a-haystack*, e ainda sofrer degradações substanciais quando o comprimento do contexto e a complexidade da tarefa aumentam (Hsieh et al., 2024).

O RULER amplia a avaliação tradicional de recuperação ao incluir diferentes tipos e quantidades de informações relevantes, além de tarefas de rastreamento em múltiplas etapas e agregação.

Hsieh et al. (2024) avaliaram 17 modelos de contexto longo em 13 tarefas.

Embora todos os modelos avaliados declarassem suportar pelo menos 32 mil tokens, apenas aproximadamente metade manteve desempenho considerado satisfatório nessa extensão.

Esse resultado reforça a necessidade de distinguir a **janela nominal de contexto**, definida pelo número máximo de tokens aceitos pelo modelo, de sua **janela efetiva**, isto é, da extensão de contexto que pode ser utilizada de maneira confiável para determinada tarefa.

5.2 O viés posicional desapareceu?

Trabalhos posteriores mostram que o problema não pode mais ser resumido pela afirmação de que os modelos simplesmente “se perdem no meio”.

Tian et al. (2025) investigaram cenários nos quais múltiplas informações relevantes estão distribuídas pelo contexto.

Os autores observaram que modelos mais recentes podem apresentar maior robustez ao padrão clássico de *Lost in the Middle*, mas continuam sujeitos a vieses relacionados à disposição das informações relevantes.

Em particular, a distância entre diferentes evidências necessárias para a resposta pode afetar o desempenho.

Esse resultado amplia o problema original: não importa apenas **onde** uma informação está localizada, mas também **como diferentes informações relevantes estão distribuídas** dentro da sequência.

5.3 NoLiMa: recuperar sem correspondência literal

Avaliações mais recentes passaram também a questionar tarefas de recuperação simples como medida suficiente da capacidade de compreender contextos longos.

O benchmark NoLiMa reduz a correspondência lexical entre a pergunta e a informação relevante, exigindo que o modelo estabeleça relações semânticas para localizar a evidência necessária (Modarressi et al., 2025).

Modarressi et al. (2025) mostram que o desempenho de modelos com suporte nominal a contextos extensos pode se deteriorar de maneira significativa à medida que o comprimento aumenta quando as pistas literais entre pergunta e evidência são removidas.

Isso evidencia uma diferença importante entre simplesmente localizar uma sequência semelhante à pergunta e identificar uma informação cuja relevância precisa ser inferida.

5.4 Contexto longo e raciocínio

A distinção torna-se ainda mais importante quando a tarefa exige raciocínio, e não apenas localização de uma informação.

Sileo (2026) argumenta que diversos testes de contexto longo utilizam textos de distração facilmente distinguíveis das informações relevantes.

No benchmark *Logic Haystacks*, o contexto é construído com distratores homogêneos e difíceis de distinguir das evidências necessárias.

Os resultados mostram que a janela efetivamente utilizável pode ser substancialmente menor em tarefas desse tipo.

De forma complementar, Hengle et al. (2026) apresentam o MLRBench, um benchmark para raciocínio multilíngue sobre contextos extensos.

O MLRBench inclui tarefas de inferência em múltiplas etapas, agregação de informações e raciocínio epistemológico.

Nos experimentos relatados pelos autores, em algumas configurações multilíngues o modelo avaliado utilizou efetivamente menos de 30% de seu comprimento nominal de contexto (Hengle et al., 2026).

Esses resultados ajudam a separar duas capacidades:

$$\begin{array}{c} \text{recuperar uma informação} \\ \neq \\ \text{raciocinar sobre informações distribuídas no contexto} \end{array}$$

Dessa forma, a discussão contemporânea sobre contexto longo não se limita mais à pergunta:

Quantos tokens o modelo suporta?

Uma avaliação mais adequada deve considerar quanto desse contexto pode ser efetivamente recuperado, relacionado e utilizado durante a tarefa.

6 O que o resultado significa na prática?

Os resultados discutidos são relevantes para sistemas que utilizam grandes volumes de informação como entrada.

Em aplicações com documentos extensos, simplesmente inserir todo o conteúdo na janela de contexto não garante que todas as partes serão utilizadas com a mesma confiabilidade.

Considere, por exemplo, a análise de um relatório com centenas de páginas.

O fato de o documento inteiro caber dentro da janela nominal não demonstra, por si só, que uma evidência localizada em qualquer posição será utilizada de maneira igualmente robusta.

O mesmo raciocínio se aplica a sistemas RAG.

Recuperar um número maior de documentos pode aumentar a quantidade de informação disponível, mas também aumenta a quantidade de conteúdo que precisa ser discriminado, relacionado e utilizado pelo modelo.

Entre os fatores relevantes estão:

- a quantidade de informação fornecida;
- a posição das informações relevantes;
- a distância entre diferentes evidências;
- a presença de informações irrelevantes ou semelhantes;
- a complexidade da recuperação;
- a necessidade de combinar múltiplas evidências;
- a complexidade do raciocínio solicitado.

Assim, **mais contexto não significa automaticamente melhor contexto**.

7 Limitações e cuidados de interpretação

O fenômeno *Lost in the Middle* não deve ser interpretado como uma regra absoluta aplicável, com a mesma intensidade, a todos os modelos de linguagem.

Os resultados de Liu et al. (2024) correspondem aos modelos, tarefas e configurações avaliados no estudo.

A rápida evolução das arquiteturas, dos métodos de treinamento e das técnicas utilizadas para ampliar janelas de contexto torna necessária a reavaliação contínua desse comportamento.

Trabalhos posteriores mostram, inclusive, que modelos mais recentes podem ser mais robustos ao padrão clássico observado originalmente, ao mesmo tempo em que permanecem sujeitos a outras limitações relacionadas à distribuição das informações e à complexidade da tarefa (Tian et al., 2025).

Também é necessário observar que benchmarks sintéticos permitem isolar determinados fenômenos, mas não reproduzem integralmente todas as situações encontradas em aplicações reais.

Por fim, o conceito de *janela efetiva* não deve ser entendido como um único valor universal associado a determinado modelo.

A quantidade de contexto utilizável depende da tarefa, da estrutura da informação e do critério de avaliação empregado.

8 Considerações finais

A ampliação das janelas de contexto tornou possível fornecer volumes cada vez maiores de informação aos grandes modelos de linguagem.

Entretanto, o trabalho *Lost in the Middle* demonstrou que a capacidade nominal de receber uma sequência extensa não deve ser confundida com a capacidade de utilizar todas as posições dessa sequência com a mesma robustez.

Trabalhos posteriores ampliaram essa interpretação.

O RULER mostrou que bom desempenho em tarefas simples de recuperação não implica necessariamente desempenho equivalente à medida que o contexto e a complexidade aumentam (Hsieh et al., 2024).

Estudos posteriores indicam também que múltiplas evidências e a distância entre elas podem afetar o desempenho (Tian et al., 2025).

O NoLiMa mostra que a recuperação se torna mais difícil quando relações semânticas precisam ser estabelecidas sem correspondências literais claras (Modarressi et al., 2025).

Finalmente, avaliações mais recentes indicam que recuperar informações de um contexto extenso e raciocinar sobre elas constituem capacidades diferentes (Sileo, 2026; Hengle et al., 2026).

Portanto, avaliar um modelo de contexto longo exige uma pergunta mais ampla do que simplesmente:

Quantos tokens esse modelo aceita?

É necessário perguntar:

Quanto desse contexto o modelo consegue efetivamente recuperar, relacionar e utilizar para realizar a tarefa solicitada?

A distinção entre **janela nominal** e **contexto efetivamente utilizável** fornece, assim, uma interpretação mais adequada das capacidades e limitações dos modelos de linguagem de contexto longo.

Referências

- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, L.; POLOSUKHIN, I. *Attention Is All You Need*. Advances in Neural Information Processing Systems, v. 30, 2017. Disponível em: <https://arxiv.org/abs/1706.03762>.
- DAI, Z.; YANG, Z.; YANG, Y.; CARBONELL, J.; LE, Q. V.; SALAKHUTDINOV, R. *Transformer-XL: Attentive Language Models Beyond a Fixed-Length Context*. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, p. 2978–2988, 2019. Disponível em: <https://aclanthology.org/P19-1285/>. DOI: <https://doi.org/10.18653/v1/P19-1285>.
- BROWN, T. B. et al. *Language Models are Few-Shot Learners*. Advances in Neural Information Processing Systems, v. 33, p. 1877–1901, 2020. Disponível em: <https://arxiv.org/abs/2005.14165>.
- LEWIS, P.; PEREZ, E.; PIKTUS, A.; PETRONI, F.; KARPUKHIN, V.; GOYAL, N.; KÜTTLER, H.; LEWIS, M.; YIH, W.; ROCKTÄSCHEL, T.; RIEDEL, S.; KIELA, D. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Advances in Neural Information Processing Systems, v. 33, p. 9459–9474, 2020. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- LIU, N. F.; LIN, K.; HEWITT, J.; PARANJAPPE, A.; BEVILACQUA, M.; PETRONI, F.; LIANG, P. *Lost in the Middle: How Language Models Use Long Contexts*. Transactions of the Association for Computational Linguistics, v. 12, p. 157–173, 2024. Disponível em: <https://aclanthology.org/2024.tacl-1.9/>. DOI: https://doi.org/10.1162/tacl_a_00638.
- HSIEH, C.-P.; SUN, S.; KRIMAN, S.; ACHARYA, S.; REKESH, D.; JIA, F.; ZHANG, Y.; GINSBURG, B. *RULER: What’s the Real Context Size of Your Long-Context Language Models?* 2024. Disponível em: <https://arxiv.org/abs/2404.06654>.
- TIAN, R.; LI, Y.; FU, Y.; DENG, S.; LUO, Q.; QIAN, C.; WANG, S.; CONG, X.; ZHANG, Z.; WU, Y.; LIN, Y.; WANG, H.; LIU, X. *Distance between Relevant Information Pieces Causes Bias in Long-Context LLMs*. Findings of the Association for Computational Linguistics: ACL 2025, p. 521–533, 2025. Disponível em: <https://aclanthology.org/2025.findings-acl.28/>. DOI: <https://doi.org/10.18653/v1/2025.findings-acl.28>.

- MODARRESSI, A.; DEILAMSALEHY, H.; DERNONCOURT, F.; BUI, T.; ROSSI, R. A.; YOON, S.; SCHÜTZE, H. *NoLiMa: Long-Context Evaluation Beyond Literal Matching*. 2025. Disponível em: <https://arxiv.org/abs/2502.05167>.
- SILEO, D. *Logic Haystacks: Probing LLMs' Long-Context Logical Reasoning (Without Easily Identifiable Unrelated Padding)*. Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 2: Short Papers), p. 66–75, 2026. Disponível em: <https://aclanthology.org/2026.eacl-short.3/>. DOI: <https://doi.org/10.18653/v1/2026.eacl-short.3>.
- HENGLE, A.; BAJPAI, P.; DAN, S.; CHAKRABORTY, T. *Can LLMs Reason over Extended Multilingual Contexts? Towards Long-Context Evaluation Beyond Retrieval over Haystacks*. Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers), p. 6128–6152, 2026. Disponível em: <https://aclanthology.org/2026.eacl-long.290/>. DOI: <https://doi.org/10.18653/v1/2026.eacl-long.290>.